

Interpreting Open Data

Tomáš Kramár, @tkramar, <http://minio.sk>

Open Data

- ” **Open data** is the idea that certain data should be freely available to everyone to use and republish as they wish, without restrictions from copyright, patents or other mechanisms of control.
- ” Public money was used to fund the work and so it should be universally available.

-- Wikipedia

**Web is full
of Open Data**

**... it's just not the
easiest kind of
data to work with.**

Open Data in Slovakia

- register of companies
- register of freelancers
- information from Statistical office
- procurements
- governmental contracts
- tax debts
- financial reports
- ...

Ideas?

Not so fast!

Barrier #1: Accessibility


```
<?xml version="1.0" encoding="utf-8"?>  
<OznameniaSpravcov xmlns:xsi="http://www.w3.org/2001/XMLSchema-instance" xmlns:xsd="http:  
  <Upadca>  
    <ObchodneMenoNazov>MRC s.r.o.</ObchodneMenoNazov>  
    <Sidlo>  
      <Ulica xmlns="">Železničná</Ulica>  
      <Cislo xmlns="">324</Cislo>  
      <Obec xmlns="">Kamenica nad Cirochou</Obec>  
      <Psc xmlns="">06783</Psc>  
      <Stat xmlns="" />  
    </Sidlo>  
    <Ico>36512966</Ico>  
  </Upadca>  
  <Spravca>  
    <Typ Kod="PO">Právnická osoba</Typ>  
    <ObchodneMenoNazov>Prvá arbitrážna k.s. </ObchodneMenoNazov>  
    <Sidlo>  
      <Ulica xmlns="">Prof. Sáru </Ulica>  
      <Cislo xmlns="">5</Cislo>  
      <Obec xmlns="">Banská Bystrica </Obec>  
      <Psc xmlns="">97401</Psc>  
      <Stat xmlns="" />  
    </Sidlo>  
    <Kontakt>prvaarbitrazna@zoznam.sk</Kontakt>  
  </Spravca>  
  <SpisovaZnackaSpravcovskehoSpisu>3K 41/2011 S 1429</SpisovaZnackaSpravcovskehoSpisu>  
  <SpisovaZnackaSudnehoSpisu>3K 41/2011</SpisovaZnackaSudnehoSpisu>  
  <DruhPodania Kod="15">Vylúčenie súpisovej zložky majetku zo súpisu</DruhPodania>  
  <TextPodania>&lt;p&gt;Spr&aacute;vca konkurznej podstaty &aacute;padcu &lt;str  
Cirochou, IČO: 36 512 966, na z&aacute;klade predch&aacute;dzej&aacute;ceho  
pr&aacute;jacuto;slu&aacute;cazen&aacute;ie pr&aacute;jacuto;tu t&aacute;jacuto;mto v s&aacute;
```

You will rarely find structured data

Výpis z Obchodného registra Okresného sú
Tento výpis má len informatívny charakter a nie je pou

Oddiel: Sro

Obchodné meno:

minio, s. r. o.

Sídlo:

Kuklovská 494/5
Bratislava 841 04

IČO:

46 058 397

Deň zápisu:

26.02.2011

Právna forma:

Spoločnosť s ručením obmedzeným

Predmet činnosti:

počítačové služby

služby súvisiace s počítačovým spracovaním údajov

kúpa tovaru na účely jeho predaja konečnému spotrebiteľovi (maloobchod) alebo iným pi
(veľkoobchod)

reklamné a marketingové služby

vydavateľská činnosť

služby súvisiace s produkciou filmov alebo videozáznamov

vykonávanie mimoškolskej vzdelávacej činnosti

činnosť podnikateľských, organizačných a ekonomických poradcov

sprostredkovateľská činnosť v oblasti služieb

sprostredkovateľská činnosť v oblasti obchodu

výroba komunikačných zariadení, spotrebnej elektroniky, počítačov a kancelárskych stroj

Spoločníci:

Michal Barla
Kuklovská 494/5
Bratislava 841 04

Tomáš Kramár
Voderadv 228


Parsing HTML is your best bet

Perils of Web scraping

- Parsing HTML
 - Plenty of edge cases
 - Malformed HTML
- Crawling whole site
 - ideal case: list of all records with links
 - usually: deep Web, hidden behind a search form

orsr.sk/vypis.asp?ID=201254&SID=2&P=0

MINISTERSTVO



Výpis z Ob
Tento výpis má len in

Oddiel: Sro

Obchodné meno: minio, s. r. o.

Sídlo: Kuklovská 494/5
Bratislava 841 04

IČO: 46 058 397

Deň zápisu: 26.02.2011

Sometimes you can try different IDs

[Úvod](#) > [O Sociálnej poisťovni](#) > [Charakteristika a činnosť](#) > [Zoznam dlžníkov](#)

Zoznam dlžníkov



opíšte text z obrázka

Odoslať

TLAČIŤ

POSLAŤ LINKU

Sometimes you need to break a CAPTCHA

Obchodné meno

Obec

Ulica

Číslo

registri vedie ObÚ

And sometimes you need to be more creative

Barrier #2: Data quality

- Noisy data
- Deliberately missing data
- **Linking data within and between datasets**

Notable OpenData projects

foaf.sk - Social network of slovak companies

- companies register, public procurements, debts, internet domains and other public data.
- 300K companies and 500K+ people
- current and historic data about companies in aggregated and usable form
- visualizes connections of people and companies as network (graphs) for deeper insights.
- 500K+ pageviews per month.

otvorenezmluvy.sk - analyzing contracts

- 300K+ scanned documents (over 1TB of raw data)
 - various formats
 - multiple sources
- fulltext and advanced faceted search
- automatic analysis of contract problematicity
- in-browser document viewer, visual annotations of any part of the contract
- embedded by largest slovak online newspaper (sme.sk)

govdata.sk - API for structured public data

- Scraping, cleaning and deduplication of many public and private data sources scattered through the web.
- Identifying and linking subjects from different datasets.
- REST-based API for searching 1.2M+ subjects in realtime.

otvorenesudy.sk - transparent court decisions

- data from Ministry of Justice
 - completely unusable site, search takes minutes to complete
- in a usable form
- fulltext search, statistics, visualisations

tender.sme.sk - public procurements

- OLAP tool built on top of Slovak procurements
- Slice the data

Pattern?

Interpret meaningless data.

Link it.

Find the (hidden) connections.

Questions?

How open is data in Austria?
What's your idea?

hello@minio.sk